



**ХИМИКОТЕХНОЛОГИЧЕН И МЕТАЛУРГИЧЕН
УНИВЕРСИТЕТ
ФАКУЛТЕТ ПО ХИМИЧНО И СИСТЕМНО
ИНЖЕНЕРСТВО
КАТЕДРА: “АВТОМАТИЗАЦИЯ НА ПРОИЗВОДСТВОТО”**

ДИПЛОМНА РАБОТА

**ТЕМА: Разработване на невронни мрежи за медицинска
диагностика**

Специалност: *“Автоматика и информационни технологии”*

Образователно-квалификационна степен: МАГИСТЪР

Дипломант: Моника Младенова Маркова **Фак. №** MC1163/...../

Ръководител на дипломната работа: проф. К. Бошнаков /...../

София, ноември 2020 г

Рецензент на дипломната работа: проф. И .Бачкова /...../

Ръководител на катедра: проф. И .Бачкова /...../



**UNIVERSITY OF CHEMICAL TECHNOLOGY AND
METALLURGY - SOFIA
FACULTY OF CHEMICAL AND SYSTEM ENGINEERING
DEPARTMENT OF INDUSTRIAL AUTOMATION**

DIPLOMA THESIS

***Title:* Development of neural networks for medical
diagnostics**

***Speciality:* Automation and Information Technology**

***Student:* Monika Mladenova Markova Fac. № MC1163**

/...../

Supervisor: /...../

/ Prof. Kosta Boshnakov/

Head of Department.....

/ Prof. I. Bachkova, PhD /

Sofia, November 2010

ХИМИКОТЕХНОЛОГИЧЕН И МЕТАЛУРГИЧЕН УНИВЕРСИТЕТ
ФАКУЛТЕТ ПО ХИМИЧНО И СИСТЕМНО ИНЖЕНЕРСТВО
Катедра: “АВТОМАТИЗАЦИЯ НА ПРОИЗВОДСТВОТО”

Специалност: *“Автоматика и информационни технологии”*

Образователно-квалификационна степен: *МАГИСТЪР*

Утвърдил:

Ръководител на катедра АП:.....
/проф.д-р инж.И.Бачкова/

З А Д А Н И Е
ЗА ДИПЛОМНА РАБОТА

на студента: Моника Маркова, фак.№ МС 1163

Тема на дипломната работа

Разработване на невронни мрежи за медицинска диагностика

1. Да се направи литературен обзор по темата невронни мрежи
2. Да се комплектуват данни от реалната медицинска практика
3. Да се разработят невронни мрежи за медицинска диагностика

Дата на получаване

на заданието 1.07.2019г.

Студент:.....

Срок за предаване

на дипломната работа

24.11.2019г

Ръководител:.....

/проф. д-р инж. К.Бошнаков/

ДЕКЛАРАЦИЯ

от Моника Младенова Маркова, фак. No MC 1163

Декларирам, че съм разработил и написал представената дипломна работа самостоятелно, следвайки напътствията и съветите на дипломния си ръководител, и използвайки само цитираните литературни източници и средства.

22.07.2020

Подпис:

Съдържание

Увод.....	7
Цел и задачи	8
Глава 1. Невронни мрежи.....	9
1.1. Същност	9
1.2. Обучение на невронните мрежи	11
1. Супервайзърно обучение	11
2. Самообучение	12
3. Насочено обучение.....	12
1.3. Биологични невронни мрежи	13
1.4. Заключение	15
Глава 2. Типове невронни мрежи.....	16
2.1. Еднослойни невронни мрежи с прави връзки (право предаване на сигнала).....	16
2.1.1. Неврон на McCulloch-Pitt	16
2.1.2. Адаптивен линеен елемент - ADaptive LINEar Element (ADALINE)	17
2.1.3. Перцептрон	18
2.2. Многослойни невронни мрежи с прави връзки (право предаване на сигнала).	20
2.2.1. Многослойни невронни мрежи използващи метода с обратно разпространение на грешката.....	20
2.2.2. Многослойни неврон мрежи с радиални базисни функции	22
2.3. Рекурентни невронни мрежи.	24
Глава 3. Значение на интелигентната медицинска диагностика.	26
3.1. Изкуствен интелект.....	27
3.2. Медицинска диагностика.....	28
3.3. Заключение	34
Глава 4. Експериментална част.	35
Пример 1.	36
Пример 2.	44
Глава 5. Изводи и заключение.....	53
Литература:.....	55

Увод

Използването на невронни мрежи в медицината обикновено е свързано със системи за диагностика на заболяванията. Невронните мрежи обаче не само са в състояние да разпознаят модели, но поддържат много важна информация. Поради тази причина една от основните области на приложение на невронните мрежи е тълкуване на медицинските данни.[1]

Изкуствените невронни мрежи са изчислителни парадигми, базирани на математически модели, които за разлика от традиционните изчисления имат структура и действие, наподобяваща тази на мозъка на бозайниците. Невронните мрежи също се наричат свързващи системи, паралелно разпределени системи или адаптивни системи, защото са съставени от поредица от взаимно свързани обработващи елементи, които работят паралелно. Невронните мрежи нямат централизиран контрол в класическия смисъл, тъй като всички взаимно свързани обработващи елементи се променят или „адаптират“ едновременно с потока от информация и правилата за адаптиране.[2]

С развитието на компютърните технологии и увеличаване на изчислителните мощности на компютърните системи, невронните мрежи се използват все по-активно, за решаване на различни задачи. Идеята за създаване на невронни мрежи е създаване на интелигентна система за паралелни изчисления, която да работи по начин, близък до човешкия мозък. Подкрепят медицинските науки, бизнеса, научните изследвания и т.н. Тези системи, когато се прилагат с голямо внимание, дават изненадващо точни резултати и отстраняват грешки, които вероятно се случват от хората. Тези системи следват определен път, за да постигнат целта, като използват предоставената информация. Други приложения са: управление на роботизирани системи, автоматизация на различни процеси, управление на риска, прогнозиране и др. Голяма част от приложния софтуер, фокусиран върху математическите изчисления на тези процеси, тяхната обработка или статистика, предлагат готови модули за създаване, обучение и работа с невронни мрежи.

Цел и задачи

Целта на дипломната работа е разработване на невронна мрежа, която да подпомага диагностиката на рак.

За изпълнението на тази цел са поставени следните задачи:

- Да се проучат същността на невронните мрежи и основните подходи за синтезирането им.
- Да се проследи възможността за приложение на изкуствен интелект в медицината.
- Да се разработи невронна мрежа за диагностика.
- Да се изследва поведението на невронните мрежи и влиянието на зададените параметри и да се направи оценка на получените резултати.

Глава 1. Невронни мрежи.

1.1. Същност.

Изкуствените невронни мрежи са нелинейни (сигнални) устройства за обработка, които са изградени от взаимно свързани прости устройства за обработка, наречени неврони.

Изкуствената невронна мрежа е пример за обработка на информация, която е вдъхновена от начина, по който биологичните нервни системи, като мозъка, обработват информацията. Ключовият елемент е новата структура на системата за обработка на информация. Състои се от голям брой силно свързани помежду си обработващи елементи (неврони), които работят в единство за решаване на специфични проблеми. Изкуствените невронни мрежи, както хората, се учат с пример. Невронните мрежи се конфигурират за конкретно приложение, като разпознаване на модели или класификация на данни, чрез процес на обучение. Ученето в биологични системи включва приспособяване към синаптичните връзки, които съществуват между невроните. Това важи и за невронните мрежи.

Невронните мрежи са вид изкуствен интелект, който се опитва да имитира начина, по който работи човешкият мозък. Вместо да използва цифров модел, при който всички изчисления оперират с нули и единици, невронната мрежа работи чрез създаване на връзки между обработващи елементи, компютърния еквивалент на невроните. Организацията и теглото на връзките определят изхода.

Невронната мрежа е мощен паралелно разпределен процесор, който има естествената склонност да съхранява експериментални знания и да ги прави достъпни за употреба. Прилича на мозъка в две отношения:


1. знанията се придобиват от мрежата чрез процес на обучение, и,
2. силите на междуневронна връзка, известни като синаптични тегла, се използват за съхраняване на знанията.

Изкуственият неврон се характеризира с:

1. Архитектура (връзка между невроните)
2. Обучение (определяне на тежести върху връзките)

3. Активираща функция

Структурата на обикновена изкуствена невронна мрежа е показана на фиг.1.1.



Фиг.1.1. Обикновена изкуствена невронна мрежа

Фигура 1 показва обикновена изкуствена невронна мрежа с два входни неврона (x_1 , x_2) и един изходен неврон (y). Вътрешните тегла са дадени чрез w_1 и w_2 . Различните входове в мрежата са представени от математическия символ $x(n)$. Всеки от тези входове се умножава по теглото на връзката. Тези тегла са представени с $w(n)$. В най-простия случай тези продукти се сумират, захранват се чрез трансферна функция за генериране на резултат и след това се доставят като изход. Това електронно внедряване все още е възможно с други мрежови структури, които използват различни функции за сумиране, както и различни функции за прехвърляне.[1]

В математически вид, функционирането на неврон се описва по следния начин. Определяме (x_1 , x_2 , x_3 , . . . , x_i) като входни сигнали, w_i синаптически тегла на неврона, а w_i като връзка между невроните. Изходните данни (z) на неврона се определят като

$$z = \sum_{i=1}^n w_i x_i$$

и са определени като линейна сумация на входните сигнали и синаптичните връзки.

Многослойната невронна мрежа е вид невронна мрежа за пряко разпространение на сигнала и се характеризира с наличието на един или няколко скрити слоя, а невроните, групирани в тези слоеве се наричат скрити неврони или скрити елементи[3]. Под термина "скрит" се разбира слой или неврон, който не се вижда пряко от входа или изхода на мрежата, като целта на скритите елементи е да допринасят за способността на

мрежата да извлече от изхода статистики от по-висок ред. Връзките между невроните в слоевете могат да бъдат описани като насочен граф и обикновено са напълно свързани[4,5]. Насоченият граф описва не само протичането на сигнала между невроните, но и как сигнала се предава в съответния неврон. Невронната мрежа за пряко разпространение може да бъде описана по следния математически модел, където l обозначава броя слоеве в мрежата, net_j^l описва j -ия неврон в слоя l . Синаптичните тегла от i -ия неврон в слой $l-1$ до j -ия неврон на слой l са представени като $w_{ij}^{l-1,l}$, а изходната стойност на j -ия неврон в слой l е представена като $f(net_j^l)$ активационна функция:

$$\sum_{i=1}^n w_{ij}^{l-1,l} y_i^{l-1} = f(net_j^l)$$

Определянето на броя скрити неврони е от изключително значение при структурирането на невронната мрежа, тъй като прекалено голямо количество неврони намаляват точността на обобщението на данните. Допълнителен проблем се състои от факта, че голямото количество неврони служи за автоматичното запомняне на обучителните данни, което премахва способността за качествено обобщение на информацията. От друга страна, недостатъчен брой неврони допринася за намаляване на обучаващата способност на мрежата и откриването на комплексни гранични стойности на проблема. Точният брой неврони в мрежата, както и във всеки скрит слой не е обоснован и е строго зависим от специфичната задача, обучителен алгоритъм и от специфични решения на учения[6].

1.2. Обучение на невронните мрежи

Обучението на невронните мрежи е процес при който чрез целенасочено изменение на тегловните коефициенти на връзките, мрежите придобиват желаните свойства или поведение. Подходите за обучение могат да се обединят в три групи. Всяка от тях е базирана на определен аспект от поведенческото обучение в биологичните системи.

1. **Супервайзърно обучение** (supervised learning). При зададени начални стойности на теглата се подава вектор с входни данни на входа на мрежата. Получената реакция на изхода се сравнява с предварително зададена (еталонна) и се намира грешката. Нейната стойност е критерий за промяна на тегловните коефициенти. Този процес продължава до минимизиране на

грешката. Затова обучението с учител е известно и под наименованието обучение с минимизиране на грешката. Прилагането му изисква задаване на образцови серии от входни данни и желани изходни сигнали, които се наричат тренировъчни комплекти. Чрез тях системата се научава да реагира по определен желан начин. При мрежите използващи обучение с учител рязко се разграничават два етапа – на трениране (когато теглата се адаптират за да бъде научено желано поведение) и на опериране (когато намерените на първия етап тегловни коефициенти са фиксирани и мрежата работи с тях при различни входни данни). Този подход за обучение широко се използва при невронни мрежи с прави връзки и някои рекурентни мрежи.


2. **Самообучение** (unsupervised learning). Теглото на дадена връзка се определя в зависимост от корелацията (съгласуваността) на активациите на свързаните чрез нея два неврона. Затова това обучение е известно и като корелационно. Първият вариант на такова обучение (предложен от Хеб) извършва актуализация на стойността на всеки тегловен коефициент в мрежата чрез добавяне към текущата му стойност на нов член, пропорционален на произведението от стойностите на активация на двата свързани неврона. Характерно за това обучение е, че то не изисква тренировъчни комплекти и не съществува разграничение между етапите на обучение и опериране на мрежата. Обучението без учител намира широко приложение при задачи, които изисква асоциативна памет, т.е. данните да не се извличат от адреси, а по асоциирани с тях значения.
3. **Насочено обучение** (reinforcement learning). При него подобно на обучението с учител също трябва да има примери с образци от входни данни, но липсва необходимостта заедно с тях да се предоставят образци с желаните реакции (изходни данни). Въвежда се обща мярка за адекватност на получените резултати, която “води” мрежата към желаното поведение. Тя обикновено се нарича усилващ или поощряващ сигнал. Той се подава като обратна връзка в мрежата, за да се поощрят коректните и съответно накажат некоректните поведения. Това става чрез увеличаване на тези тегла, които са допринесли за доброто поведение и намаляване на тези, предизвикали лош резултат[8].

1.3. Биологични невронни мрежи.

Биологичният неврон или нервна клетка се състои от синапси, дендрити, клетъчно тяло и аксон. Строителните блокове се разглеждат, както следва:


- Синапсите са елементарно устройство за обработка на сигнала. Те са биохимично устройство, което преобразуват пресинаптичния електрически сигнал в химичен сигнал и след това обратно в постсинаптичен електрически сигнал. Амплитудата на входния импулс е модифицирана от параметри, съхранени в синапса. Естеството на тази модификация зависи от вида на синапса, който може да бъде или инхибиторен, или възбуждащ.
- Постсинаптичните сигнали се събират и пренасят по дендритите към тялото на нервните клетки.
- Клетъчното тяло генерира изходния неврален сигнал, шип, който се пренася по аксона към синаптичните терминали на други неврони.
- Честотата на изпращане на сигнал на неврон е пропорционална на общите синаптични дейности и се контролира от синаптичните параметри (тегла).
- Пирамидалната клетка може да получи 104 синаптични входа и може да разпръсне изходния сигнал към хиляди целеви клетки - свързаност, трудно постижима в изкуствената невронна мрежа. [1]

На фиг. 1.2. са показани биологичен неврон и изкуствен неврон.



Фиг.1.2. Биологичен и изкуствен неврон.

Ако подредим няколко неврона успоредно и след това в различни слоеве, получаваме карта от входа към изхода. Предвид определена задача можем да изберем различна мрежа. Трябва да знаем: каква е силата на една мрежа. За двуслойна мрежа (фиг. 1.3), съдържаща поне един нелинеен слой, ние знаем, че можем да приближим всяка функция толкова близо, колкото желаем [2].



Фиг.1.3. Двуслойна мрежа.

В днешно време изкуственият интелект е широко развит в своите приложения за решаване на проблемите на реалния свят. Медицинската диагноза е един от най-важните аспекти на човешкия живот, който е забелязан от много изследователи и учени. В медицинската диагноза има някои трудности, които причиняват грешки на лекаря по време на процеса. Много от трудностите са свързани с огромното количество медицински данни, сходството на симптомите за много от заболяванията и лекарските умения и опит. Такива причини насърчават изследователите и учените в областта на компютърните науки и инженерните науки да работят усилено, за да проектират усъвършенствани интелигентни инструменти и техники за диагностициране на болестта с приемливи резултати, за да спасят човешкия живот. Прилагането на изкуствен интелект за повишаване на надеждността при вземане на медицински решения се изучава от преди няколко години и много изследователи са изследвали в тази област.

Един от най-важните проблеми на медицинската диагностика като цяло е субективността на специалиста. Може да се отбележи, по-специално в дейностите по разпознаване на образци, че опитът на специалиста е тясно свързан с окончателната диагноза. Това се дължи на факта, че резултатът не зависи от систематизирано решение, а от интерпретацията на сигнала на пациента.

За медицинската диагноза трябва да бъдат използвани различни изследователски области, за да се увеличи ефективността на това. Например системите за управление на база данни се използват за съхраняване, извличане и манипулиране на данни за пациенти, докато експертните системи се използват главно за извършване на диагнози въз основа на данни за пациентите. Диагнозата на костните заболявания се улеснява значително от използването на методите на нуклеарната медицина, по-конкретно от използването на сцинтиграфски изображения (или скенер) и са разработени редица съответни експертни системи.

1.4. Заключение


Медицинската диагноза не е 100% надежден процес. И машини, и лекари грешат. Вярно е обаче да се мисли, че не всички лекари извършват еднакво медицинско лечение. Въпреки огромното развитие на биомедицинската технология, диагностичната точност в много случаи е доста ниска. Причината е, че медицинските инструменти не предоставят достатъчно подходяща информация за надеждна диагноза. Проблемът обаче е в тълкуването на данните за пациента. Използвайки машинно обучение, би могло да се облекчи този проблем чрез автоматично генериране на диагностични правила от записите на пациенти с известни диагнози. Колкото по-интелигентна и опитна е машината, толкова по-надеждно е вземането на медицински решения.

Глава 2. Типове невронни мрежи.

2.1. Еднослойни невронни мрежи с прави връзки (право предаване на сигнала).

2.1.1. Неврон на McCulloch-Pitt

Невронът на McCulloch-Pitt е предложен през 1943 г. и чрез него за първи път се илюстрира идеята на използването на невронните мрежи за различни изчисления. Той се характеризира с изчислителна универсалност, тъй като всяка логическа функция може да бъде изчислена с мрежа от неврони на McCulloch-Pitt. Той е показан на фиг. 2.1 Същевременно всяка крайна последователност от дискретни действия може да бъде стимулирана с рекурентни невронни мрежи от такива неврони.



Фиг.2.1. Неврон на McCulloch-Pitt.

При него теглата са фиксирани, т.е. не се настройват с обучение. Входните сигнали x_1, x_2, \dots, x_m и изходните сигнали y на невроните са бинарни, т.е. $x_i \in \{0, 1\}$, $y \in \{0, 1\}$, като входовете биват два вида – възбудителни и забранителни. Теглата, свързани със възбудителните входове x_1, x_2, \dots, x_k са отрицателни. Всеки ненулев входен сигнал на някой от забранителните входове x_{k+1}, x_2, \dots, x_m генерира нулев изходен сигнал. Изходен сигнал 1 се получава, когато сумата от теглата на възбудителните входове, свързани с ненулеви сигнали е по-голяма от предварително зададен праг θ и няма сигнал на никой от забранителните входове [2]:

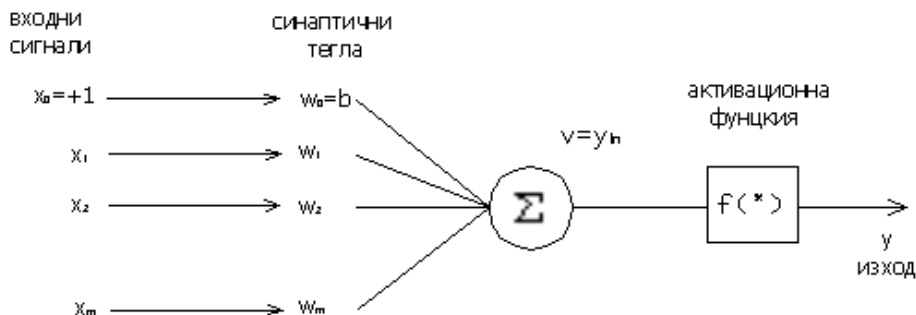
$$y = \begin{cases} y=1, & \text{когато } \sum_{j=1}^k w_j^+ x_j \geq \theta \text{ или } x_i=0, i=k+1, \dots, m \\ 0, & \text{когато } \sum_{j=1}^k w_j^+ x_j < \theta < \text{ или } i=k+1, \dots, m, \text{ такова че } x_i=1 \end{cases}$$

За правилната работа на неврона трябва да е изпълнено условието

$$\sum_{j=1}^k w_j^+ - w_i^- < \theta, \quad \forall i = k+1, \dots, m$$

2.1.2. Адаптивен линеен елемент - ADaptive LINear Element (ADALINE)

Адаптивният линеен елемент - ADaptive LINear Element (ADALINE) е предложен през 1962 г. от Bernard Widrow. Той представлява единичен неврон (фиг.2.2) с линейна активационна функция и настройващи се тегла. Алгоритъмът на Windrow-Hoff за настройка на теглата се базира на метода на най-малките квадрати и е пример за използване на обучение при настройката. Той е в основа за различни видове адаптивна филтрация използвана при обработка на сигнали.



Фиг.2.2. Единичен неврон с линейна активационна функция (ADALINE)

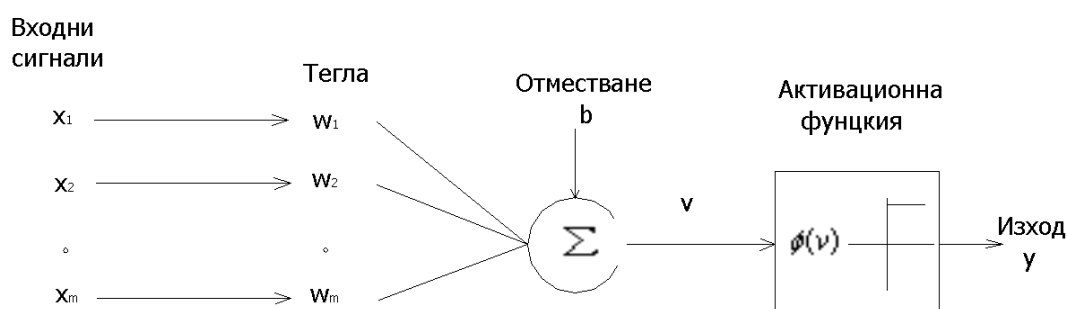
За обучението на мрежите от тип ADALINE е необходимо да се разпалага с обучаваща извадка с обем p , представляваща набори от входни сигнали и желан (еталонен) изход на мрежата за всеки от тях. При подаване на всеки k -ти комплект входни сигнали, се определя изходът от невронната мрежа и грешката e_k между него и еталонния изход при зададената комбинация на входа. Целта на обучението е да бъдат

настроени теглата $w = [w_1 \ w_2 \ \dots \ w_m]^T$ така, че да бъде минимизирана интегралната грешка $\sum_{i=1}^p e_i$ за цялата обучаваща съвкупност. В различни варианти на обучаващите алгоритми промяната на теглата се прави след всеки компонент от обучаващата серия или след едно цялостно нейно изчерпване (т.е. след всяка епоха). Във всички случаи промяната на теглата е пропорционална на съответния входен сигнал, грешката и параметър η , наречен скорост на обучение.

Мрежите Адалайн принадлежат към общия клас алгоритми, наречени адаптивни линейни филтри. Те намират приложение в много области като например за проектиране на изравняващи филтри при високоскоростни модеми, за адаптивни ехокомпенсатори при телефонни разговори на големи разстояния и сателитни комуникации, както и за предсказване на сигнали. Намират приложение и в медицината например за подтискане на шума от биене на сърцето на майката при ембрионална електрокардиография.[10]

2.1.3. Перцептрон

Перцептронът е предложен през 1957 г. от Frank Rosenblatt. За разлика от адаптивния линейен елемент перцептронът е нелинеен неврон. Той използва релейна активационна функция (фиг.2.3).



Фиг.2.3 Перцептрон

Изходът на суматора се изчислява като

$$v = \sum_{j=1}^m w_j x_j + b = \sum_{j=0}^m w_j x_j,$$

където $w_0 = b$, а x_0 е сигнал с постоянна стойност 1. Изходният сигнал y на перцептрона се определя с формулата :

$$y = \phi(v) = \begin{cases} 1, & \text{ako } v \geq \theta \\ 0, & \text{ako } v < \theta \end{cases}$$

където θ е праг на активация на перцептрона, и ако стойността му не е спомената специално се счита, че е нула $\theta = 0$.

При перцептрона се използва обучение с учител. При този тип обучение критерият за обучението се задава с комплект примерни входно-изходни последователности за желаната работа на мрежата от типа

$$\{p_1, d_1\}, \{p_2, d_2\}, \dots, \{p_Q, d_Q\},$$

където p_Q е образ, подаван на входа на мрежата, а d_Q е съответната правилна (желана) стойност на изхода на мрежата при подаване на p_Q . С прилагане на входните елементи към мрежата се сравняват получената стойност на изхода на мрежата с желаната стойност, зададена от съответното d . След това се стартира алгоритъм за обучение, посредством който се променят (настройват) теглата и отместванията на мрежата така, че получаваната стойност на изходите на мрежата да се доближават до желаната.

Алгоритъмът, прилаган при обучението на перцептрона е следният :

$$\text{ако имаме } d=0 \text{ и } f(w^T x) = 1, \text{ то тогава } w_{new} = w_{old} - x,$$

$$\text{ако имаме } d=1 \text{ и } f(w^T x) = 0, \text{ то тогава } w_{new} = w_{old} + x,$$

$$\text{ако имаме } d = f(w^T x), \text{ то тогава } w_{new} = w_{old},$$

където с w_{new} се означава новата, а с w_{old} старата стойност на тегловия коефициент от преходната интерация. С x се означава съответната стойност на P_Q , подадена на входа, а с d - съответното d_Q . Функцията $f(w^T x)$, имаща релеен характер, приема в случая стойности 0 или 1, т.е.

$$y = f(v) = \begin{cases} 1, & v \geq \theta \\ 0, & v < \theta \end{cases}$$

Ако бъде въведена грешка $e = d - f(w^T x)$, правилото за обучение може да бъде представено в следния компактен вид : $w_{new} = w_{old} + ex$.

Горното правило може да се обобщи за един слой от k на брой перцептрони, използващи едни и същи входни сигнали $x = [x_1 \ x_2 \ \dots \ x_m]^T$. В този случай формулите за настройка на вектора с теглата w_i и отместване b_i , свързани с i -тия перцептрон, са равни на :

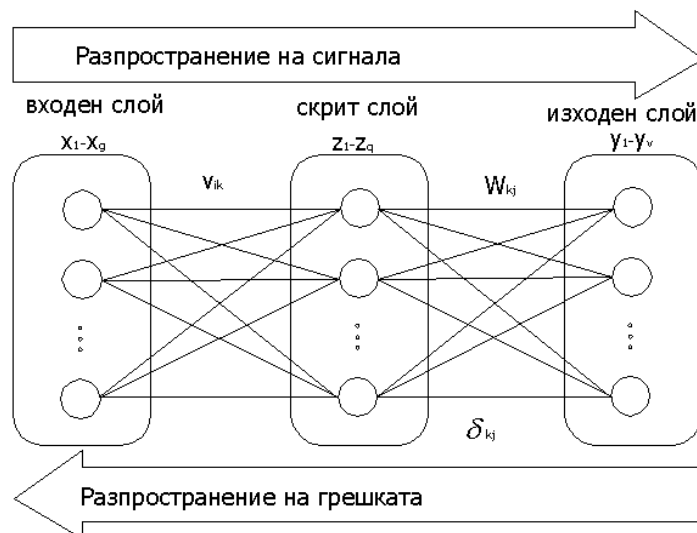
$$w_{i_new} = w_{i_old} + e_i x, \quad b_i = b_i + e_i,$$

където $e_i = d_i - f(w_i^T x + b_i)$.

2.2. Многослойни невронни мрежи с прави връзки (право предаване на сигнала).

2.2.1. Многослойни невронни мрежи използващи метода с обратно разпространение на грешката

На практика най-често използваните многослойни мрежи са двуслойни, защото е доказано, че при достатъчно неврони в междинния слой, всяка двуслойна мрежа може да реализира функциите на мрежа с повече слоеве. Архитектурата на двуслойна невронна мрежа с еднопосочно предаване на сигнала, използващи метода с обратно разпространение на грешката е показана на фиг 2.4.



Фиг.2.4. Невронна мрежа с едностранно предаване на сигнала, използваща метода с обратно разпространение на грешката .

Всички алгоритми за обучение на многослойните невронни мрежи се основават на алгоритъма с обратно разпространение на грешката, който е известен още като обобщено делта правило. В основата си той представлява градиентен метод, целящ минимизиране на грешката на изхода на мрежата.

Обучението на многослойните невронни мрежи преминава през три етапа. По време на първия, наречен право разпространение, всеки входен неврон получава входен сигнал и го изпраща на всеки от невроните от скрития слой. Невроните в скрития слой, от своя страна, формират своя изходен сигнал на тази база и го изпращат на невроните от изходния слой. В края на процеса изходните неврони изчисляват своите изходни сигнали и по този начин формират реакцията на мрежата на подаденото входно въздействие.

На следващия етап от обучаващия процес, реакцията на всеки изходен неврон се сравнява с желаната реакция с цел определяне на грешката. На нейна основа се определя коефициентът δ_k за всеки неврон в изходния слой. Коефициентът δ_k се използва, за да се разпредели грешката от изходния слой към предходния. По-късно тя се използва за преизчисляване на теглата между скрития и изходния слой. По подобен начин се изчислява и δ_j за скрития слой. Не е необходимо разпространението на

грешката назад към входните неврони, но тя се използва за обновяване на стойността на тегловните коефициенти между входа и скрития слой.

След като всички коефициенти δ бъдат определени, теглата на всички слоеве на мрежата се обновяват едновременно.

Активационната функция на мрежата с обратно разпространение на грешката трябва да има няколко важни свойства – да бъде непрекъсната, диференцуема и монотонно нарастваща. Освен това, с цел изчислителна ефективност, е желателно производната ѝ да бъде лесна за изчисление. Друго условие е функцията да има крайни максимум и минимум, които да се достигат асимптотично. Най-често използваната функция, отговаряща на горните условия, е сигмоидалната.

Многослойните мрежи, използващи обучение с обратно разпространение на грешката имат няколко съществени предимства :

- Могат да представят всяка интегрируема функция.
- Нуждаят се само от подходяща обучаваща извадка.
- Не изискват предварително познаване на проблемите (т.е. способни са да решават лошо структурирани задачи).
- Устойчиви са на шум и липса на данни от обучаващата извадка.

Наред с това притежават някои недостатъци:


- Обучението може да бъде продължително.
- При обучението на мрежата е възможно спиране на алгоритъма в локален минимум вместо достигането до глобалния оптимум.

За преодоляване на последния проблем са предложени редица модификации на обучаващия базов алгоритъм. Един ефективен подход е ново стартиране на обучението с променени начални тегла и/или променен ред на обучаващите комплекти в извадката.⁹

2.2.2. Многослойни неврон мрежи с радиални базисни функции

Идеята при въвеждане на тези мрежи е свързана с използването на линейни разделящи правила при класификация на образи. За двумерния пример от фиг.2.5, двата


вида образи са разделими с нелинейна крива (показаната окръжност), но са линейно неразделими, т.е. не съществува права която да ги разделя.



Фиг.2.5. Двумерен пример

От теоремата на Cover е известно, че образите които са нелинейно разделими в пространство с ниска разделяемост, е възможно да бъдат разделени в пространство с по-голяма размерност. Ето защо се търси мрежа, способна да извършва нелинейна трансформация на данни от едно пространство в друго с по-висока размерност и така да ги направи линейно разделими.

Мрежите способни да се справят с този проблем, са мрежи с радиална базисна функция, които са дадени на фиг. 2.6. Те са двуслойни мрежи, чиито неврони в скрития слой имат нелинейна активационна функция (радиални базисни), а невроните в изходния слой – линейни активационни функции.



Фиг.2.6. Мрежа с радиални базисни функции.

Трите основни параметъра, които влияят на качеството на мрежата с радиални базисни функции, са :

- центрове на радиално-базисни функции.
- ширините σ на радиално-базисните функции.
- теглата на връзките в изходния слой.

При обучение на тези мрежи обикновено центровете и ширините на радиално-базисните функции се определят „без учител“, а за теглата се използва обучение „с учител“.

Ширината на функциите се изчисляват по формулата : $\sigma = \frac{d_{\max}}{\sqrt{2m}}$,

където d_{\max} е максималното разстояние между два неврона, а m – броят на невроните в скрития слой. Това гарантира, че функцията няма да е твърде плоска или твърде изпъкнала.

Предимствата на мрежите с радиално базисни функции пред стандартните мрежи, използващи алгоритъм с обратно разпространение на грешката, са в това, че те имат по-бързо обучение и по-сигурно достигане до глобалния минимум в пространството на грешката. Недостатък на тези мрежи е, че много често изискват по-голям брой неврони в скития слой. [9]

2.3. Рекурентни невронни мрежи.

При разглежданите до момента невронни мрежи информацията се пренася само в една посока – последователно от входния, през скритите слоеве, ако има такива, до изходния слой. Затова те се наричат с прави връзки. Съществуват такива мрежи при които информация се движи и в обратна посока – към текущия или към предходни слоеве на мрежата. Тези мрежи се наричат рекурентни мрежи. Следователно когато на една рекурентна мрежа се подаде входен вектор, той не продуцира изходен вектор след краен брой стъпки, а предизвиква кръгов процес или “резонанс” на нервната активност в мрежата. В резултат на това едни и същи слоеве се активират многократно. Ако мрежата резонира известно време и след това се установи в устойчиво състояние, тя се нарича собственоустойчива. Целта на тренирането на рекурентните мрежи е да се

намерят такива тегла на връзките, които да гарантират собствена устойчивост на мрежата при стабилизиранни стойности на изхода, съответстващи с еталонни, зададени за обучаващите входни серии. [11]

Предложени са множество различни архитектури на рекурентни невронин мрежи. Едни от най-разпространените са предложените от Hopfield, Елман и Джордан.

Глава 3. Значение на интелигентната медицинска диагностика.

В реалния свят има различни проблеми и някои от тях са по-значими в сравнение с други. Медицинската диагноза е един от тези значими проблеми. Основната причина е, че медицинската диагностика и лечение са свързани с живота и тялото на човека. Всяка грешка ще изправи човешкия живот в опасност. Освен това, в случай на някаква болест, свързана със сърцето и мозъка, медицинската диагноза става по-важна. Всяко заболяване има свои уникални симптоми. Този въпрос затруднява работата на лекаря и увеличава вероятността от грешна диагноза.

Основната задача на медицинската наука е да предотвратява и диагностицира заболяването. Фокусът е втората задача, която не е лесна. Всички лекари се сблъскват със задачата да се научат да диагностицират. Тук те трябва да решат проблема с извеждането на определени заболявания или да формулират лечение въз основа на повече или по-малко определени наблюдения и знания.

Медицинската диагноза е била един от най-трудните въпроси на човека преди и сега и за това има разумни обосновки. Изброени са някои трудности при медицинската диагностика, които трябва да бъдат взети под внимание:

- Основата за валидна диагноза, достатъчен брой опитни случаи, се достига след опит в практиката на лекаря.
- Това важи особено за редки или нови заболявания, при които и опитни лекари са в същото положение като новодошлите.
- По принцип хората не приличат на статистически компютри, а на системи за разпознаване на образци. Хората могат много лесно да разпознават модели или обекти, но се провалят, когато вероятностите трябва да се присвояват на наблюденията.
- Качеството на диагнозата зависи изцяло от уменията на лекаря, както и от неговия опит.
- Емоционалните проблеми и умората влошават работата на лекаря.
- Процедурата за обучение на лекари, по-специално на специалисти, е продължителна и скъпа.
- Медицинската наука е една от най-бързо развиващите се и променящи се области на науката. Новите резултати изместват по-старите лечения, нови лекове и нови лекарства се въвеждат всеки ден. Дори неизвестни болести се

появяват от време на време. Следователно, лекарят винаги трябва да се старее да поддържа себе си в течение.

3.1. Изкуствен интелект.

Идеята за проектиране на интелигентен компютър доведе до започване на нова област на изследване за изследователите. Те се опитаха да направят изкуствен мозък с помощта на компютри. С други думи, изкуственият интелект е наука, която се опитва да направи компютрите по-интелигентни. Вярно е да се мисли, че изкуственият интелект е област на изследване за подражаване на човешкия интелект в компютърна технология.

Медицинската изкуствена интелигентна система има различна роля в научните изследвания. Интелигентната система има способността да се учи и да бъде обучавана от експерта или дори да създава нови медицински знания. Например компютърна система може да се използва за анализ на големи количества данни, търсейки сложни модели в тях, които предполагат неочаквани преди това асоциации. По същия начин, системата за изкуствен интелект има способността да класифицира медицинските символи на базата на различни видове заболявания.

Изкуственият интелект в медицината използва медицински приложения с изкуствен интелект. Те се прилагат широко за здравето на хората и са главно отговорни за диагностичните задачи. Процесът на диагностика може да се манипулира чрез предоставяне на адекватни данни и знания. Изкуственият интелект в медицината работи в рамките на електронна система за медицинска документация и лекарят ще бъде предупреден, ако открие някакви противопоказания за планирано лечение или ще бъде алармиран, ако открие модел, който има значителни промени в състоянието на пациента.

Приложението на системите за изкуствен интелект в медицината е тяхното използване в същината за подобряване на здравеопазването. Има три основни подхода за анализ на медицинските данни:

- Клиничен алгоритъм или блок-схема
- Съвпадение на случаи с големи бази данни от предишни случаи.
- Приложения на решенията.

Всеки от тях има забележителни успехи, но и по-ограничена приложимост.

Моделирането на експертното поведение на компютрите в медицината върху опита на човешките консултанти в никакъв случай не е логично необходимо. Чрез разбиране на функционирането на подробния процес на заболяването е възможно да се извърши диагностика чрез приспособяване на проектирания модел към действително наблюдаваните характеристики на пациентите, които са налични. Освен това можем да изпробваме възможни терапии на модела, за да изберем оптималната за пациента. Методологията, предложена от изкуствения интелект в медицината, никога не отхвърля догматично използването на нечовешки подходи. Въпреки това, по-голямата част от информацията, която знаем за лекарството, е от най-добрите специалисти по хуманна медицина. Следователно методите, които сме склонни да изграждаме в интелигентната система, са имитация на тези, използвани от специалиста.

3.2. Медицинска диагностика.

Поради важността на използването на интелигентни методи за повишаване на точността на медицинските системи за вземане на решения, използването на изкуствен интелект за медицинска диагностика се превърна в основна задача. Медицински изкуствен интелект се занимава основно с изграждането на програми с изкуствен интелект, които извършват диагностика и правят препоръки за терапия. За разлика от медицинските приложения, базирани на други методи за програмиране, като чисто статистически и вероятностни методи, медицински програми с изкуствен интелект се основават на символичните модели на лица на заболявания и връзката им с фактори на пациентите и с клинични прояви.

Интелигентната система за медицинска диагностика може да осигури помощ за пациенти и медицински експерти. Интелигентната система може да послужи за подобряване на качеството на медицинската диагноза, повишаване на услужливостта от страна на пациентите и минимизиране на ятрогенните заболявания и медицинските грешки. Приложенията за медицинска диагностика използват изкуствен интелект, за да намалят разходите, времето, човешките грешки при вземането на медицински решения. Използват се интелигентни методи за автоматично извеждане на диагностични правила от описанията на пациентите, лекувани в миналото, за които са били проверени окончателните диагнози. След извеждане на диагностичните правила, лекарите ги използват, за да направят по-надеждната лечение.

Невронните мрежи се прилагат при диагностицирането на: рак на млечна жлеза, бърбечноклетъчен карцином, колоректален рак, лезии на множествена склероза, рак на дебелото черво, панкреатична болест, гинекологични заболявания и ранен диабет. В допълнение, невронните мрежи се прилагат и при анализа на данните и диагностичната класификация на пациенти с неизследвана диспепсия в гастроентерологията и в търсенето на биомаркери. Разработена е нова, обща, бърза и адаптивна система за диагностика на заболяването, базирана на изучаването на векторно квантоване на невронни мрежи. Този алгоритъм е първият предложен адаптивен алгоритъм и може да се прилага за напълно различни заболявания, както е доказано от постигнатата 99,5% точност на класификация, както за рак на гърдата, така и за щитовидната жлеза. Ракът, диабетът и сърдечно-съдовите заболявания са сред най-сериозните и разнообразни заболявания. Количеството данни, идващи от инструменталния и клиничния анализ на тези заболявания, е доста голямо и затова разработването на инструменти за улесняване на диагностицирането е от голямо значение.

Уеб-базирана и прогнозирана медицинска диагностика се състои от четири компонента, както следва:

- Бази данни: базите данни се състоят от информация за пациенти и за заболяванията на пациенти. Данните за пациентите като име, адреси и други подробности се съхраняват в базата данни на пациентите. Друга база данни е, която съхранява цялата информация за заболяването на пациентите. Съхраняват известна информация, включително видове заболявания, лечението и други подробности за изследванията и прилагането на терапията. Причината за отделянето на данните за пациентите от другите данни е да се подобри съхраняването на записите на пациентите.
- Модул за предсказване: Има две основни характеристики за веб-базирана медицинска диагностика и прогнозиране: модул за предсказване и модул за диагностика. В модулите за предсказване невронните мрежи се използват за предсказване на заболяването. Приложените данни за модула за предсказване се предоставят от базата данни за пациенти и заболяванията им, която ще се използва за обучение и тестване.
- Диагностичен модул: Диагностичният модул се състои от експертен опит, занимаващ се със същите случаи. Комуникацията между лекари или специалист от друга сфера помага на лекаря за диагностициране на пациента и

осигурява подходящо лечение. В телемедицината мултимедията и интернет (или компютърната мрежа) са два от основните инструменти, които подпомагат сътрудничеството и разпространението на информация. Мултимедията е комбинация от медии като текст, аудио, визуализация и графика, които могат да се използват в медицински приложения, като например при предаване на изображения.

- Потребителски интерфейс: Потребителски интерфейс, съставен от HTML файлове, които осигуряват удобства за потребителя да използва системата за диагностика. Тези файлове са свързани с информация за пациентите, симптоми и т.н.

Медицинската диагноза е била един от най-трудните въпроси на човека и преди, и сега. Това не е 100% надежден процес. И машина, и лекар могат да сгрешат. Вярно е обаче да се мисли, че всички лекари не извършват еднакво медицинско лечение. Човекът ще прилага различни методи, за да повиши качеството на медицинската диагностика. Особено компютърно базираните подходи имат важна роля в областта на медицинските услуги. Интелигентната система за медицинска диагностика може да осигури помощ за пациенти и медицински експерти. Използват се интелигентни методи за автоматично извеждане на правилата за диагностика от описанията на пациентите, лекувани в миналото, за които са били проверени окончателните диагнози. След извеждане на правилата за диагностика, лекарите ги използват за изготвяне на по-надеждното лечение.

Един типичен диагностичен процес: анамнестичните данни се получават по време на разговор с пациента и веднага след това лекарят записва данните за състоянието по време на предварителния преглед на пациента. Възможно е да се направи допълнителен лабораторен преглед за пациента в зависимост от анамнестичните данни и данните за състоянието. За всяко заболяване има редица симптоми (данните на пациента), които допринасят за диагностицирането на заболяването. Но някои от симптомите са по-значими от други. Понякога комбинация от симптоми дават по-добра представа за диагностициране на заболяване. Тогава лекарят взема предвид цялото налично описание на данните на пациента за здравословното му състояние, за да определи диагнозата. В зависимост от диагнозата се предписва лечението и след лечението целият процес може да се повтори. Във всяка итерация диагнозата може да бъде потвърдена, усъвършенствана или отхвърлена.

Определението на окончателната диагноза зависи от медицинския проблем. При някои проблеми първата диагноза е и окончателната, при други окончателната диагноза се определя след получаване на резултата от лечението, а за някои от болестите не е начин да се получи 100% надеждна окончателна диагноза. Пример е проблемът с локализацията на първичния тумор, за необходима операция за получаване на окончателната диагноза, при която се проверява местоположението на първичния тумор, въпреки че това изследване се избягва и заменя с други лабораторни изследвания. При диагностицирането на рак на гърдата, за да се предскаже рецидив на тумора след отстраняване на гърдата, са необходими пет години след операцията до окончателна проверка за прогнозата. В урологията, при проблема с диагностицирането на типа инконтиненция, на практика окончателната диагноза никога не се получава, тъй като няма практически начин за проверка на диагнозата.

Медицинската диагноза зависи от наличните данни и от опита на лекаря, неговата интуиция и пристрастия и дори от психо-физиологичното състояние на лекаря. Различни проучвания показват, че диагнозата на пациент може значително да се различава, ако пациентът е изследван от различни лекари или дори от един и същ лекар по различно време.

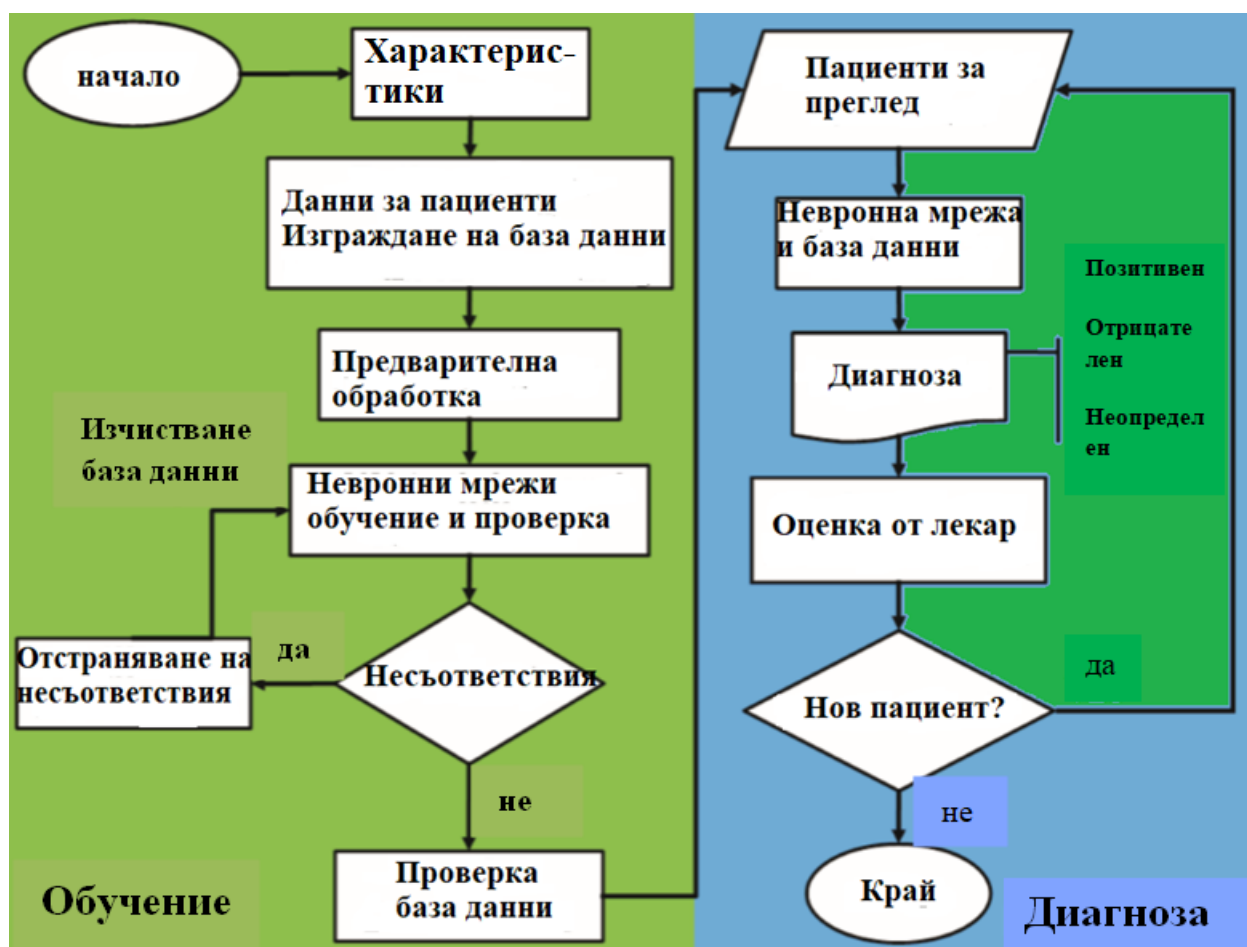
Лекарят често наблюдава състоянието на пациента по време на преглед по отношение на интуитивни впечатления, тъй като някои състояния на пациента не могат да бъдат официално описани и следователно не могат да бъдат въведени в компютъра. В някои случаи липсата на такава информация може да бъде от решаващо значение за получаване на надеждна диагноза. Въпреки че интелигентните системи могат да предизвикат по-надеждни диагностични алгоритми от ограниченото описание на пациента, такива диагностични инструменти определено не могат и също не са предназначени да заменят лекарите, а по-скоро трябва да се разглеждат като полезни инструменти, които могат да подобрят ефективността на лекарите. Диагностичната точност от лекарите може да бъде подобрена с помощта на машинно обучение.

Изчертаването на диаграми е ефективна стратегия за извличане на правила за проектиране на интелигентна система. Лекарите диагностицират заболяването въз основа на поточни диаграми. Следователно всеки компютърен експерт може да ги приложи като надежден подход за извличане на медицинска информация. Графично представяне на последователност от операции, използващи символи за представяне на

операцията, е медицинска диаграма на потока. Използвайки блок-схемите, най-важните стъпки от даден процес са символизирани, без подробности за алгоритъма за неговото изпълнение. Блок-схема или изображение могат да бъде източникът на данни. Важно е обаче да се извлекат ефективни функции, тъй като инструментите за машинно обучение могат да използват цифрови данни. Изображение или всеки параметър в диаграма се нарича функция, която може да се приеме като непрекъснат или дискретен номер, който му се присвоява. Двата процеса на извличане на елементи се състоят от две части: първата е конструкцията на характеристиките, а втората е изборът на характеристика. В етапа на конструиране на характеристиките дизайнерът на системата работи, определяйки изображението или параметър в диаграма. Този етап е начин за анализ на данните и е ключов фактор за увеличаване на успеха на системата. Изборът на функции е избор на най-подходящите и информативни функции, за да се конфигурира подходящ набор от данни като входове на инструментите за машинно обучение.

Ракът на гърдата, който е втората най-голяма причина за смъртност от рак при жените, се изследва с помощта на блок-схеми, за да се покаже процедурата за откриването му от лекарите. Процедурата предвижда няколко стъпки за събиране на данните нужни за разработване на изчислителната система за диагностика на рак на гърдата. Автоматичната диагноза на рака на гърдата е важен медицински проблем в реалния свят. Основен клас проблеми в медицинската наука включва диагностиката на заболяването въз основа на различни тестове, извършени върху пациента. Когато са включени няколко теста, крайната диагноза може да бъде трудна за получаване, дори за медицински експерт. През последните няколко десетилетия това доведе до компютърни диагностични инструменти, предназначени да помогнат на лекаря да разбере смисъла от объркването на данните.

Работният процес на анализ чрез невронни мрежи, показан на фиг. 3.1, който предоставя кратък преглед на основните стъпки, които трябва да се следват за прилагане на невронни мрежи за целите на медицинската диагноза с достатъчно увереност.



Фиг.3.1. Диаграма на основните стъпки в медицинската диагностика, базирана на невронни мрежи. Изграждането на базата данни и „ученето“ представляват лявата половина (зелено), а приложението ѝ за диагнозата е дясната част (синьо).

Мрежата получава данни на пациента, за да прогнозира диагнозата на определено заболяване. След установяване на болест следващата стъпка е правилното подбиране на характеристиките (например симптоми, лабораторни и инструментални данни), които предоставят необходимата информация, за да се разграничат различните здравни състояния на пациента. Това може да стане по различни начини. Следователно, на първия етап трябва да се извърши внимателен подбор на подходящи характеристики. В следващата стъпка базата данни се изгражда, потвърждава и „почиства“ от неточности. След обучение и проверка, мрежата може да се използва на практика за прогнозиране на диагнозата. Накрая прогнозираната диагноза се оценява от клиничен специалист. [14]

3.3. Заключение

Невронните мрежи представляват мощен инструмент за подпомагане на лекарите при поставяне на диагноза и други мерки. В това отношение невронните мрежи имат няколко предимства, включително: Способността за обработка на голям обем данни, намалена вероятност за пренебрегване на съответната информация, намаляване на времето за диагностика. Освен това използването им прави диагнозата по-надеждна.

Глава 4. Експериментална част.

Целта на експеримента е изготвяне на модел на невронна мрежа, който може да допринесе за улесняването на медицинския специалист при взимане на решение за диагностика на ракови заболявания. На база примери е представен опитът чрез невронни мрежи да се апроксимират данните от входните сигнали, както и влиянието на параметрите на мрежата върху получените резултати.

Анализът на невронната мрежа е извършен с помощта на софтуер Matlab, който съдържа различни видове toolbox-ове в различни инженерни области. Matlab е удобна среда за проектиране и изследване на невронни мрежи, тъй като притежава набор от функции за работа с тях, има голям брой toolbox-ове, позволяващи решаване на многообразни задачи от различни области. Една от възможностите за проектиране на невронна мрежа е функцията Neural Network Fitting Tool (nftool). Основните критерии включват създаване на база данни, в нашия случай на пациенти преминали хистологично изследване на базата на което може да се оцени дали пациентът има злокачествен (означен с 1) или доброкачествен (означен с 0) рак. След това данните прминават тест и валидация. Колкото по-продължително е обучението толкова по-добра е възможността за апроксимация на данните. Ако обучението не спре при достигане на минимум на грешката е възможно грешката да започне да нараства. Затова данните се разделят. По-голямата част са разпределени за обучение, по подразбиране това са 70%, а останалите 30% се разпределят за валидиране и тестване. Процентите на данните могат да варират в зависимост от целите на изследването. Максималният брой на циклите е 1000. Функцията nftool създава многослойна мрежа с право предаване на сигнала. Съществуват правила за определяне на невроните в скрития слой. По подразбиране те са 10. Могат да се променят с цел по-добро обучение на мрежата. Основните алгоритми за обучение, които могат да се използват са 3: Levenberg-Marquard - Този алгоритъм обикновено изисква повече памет, но по-малко време. Обучението автоматично спира, когато средната квадратична грешка на валидиращите проби започне да се увеличава; Bayesian Regularization - Този алгоритъм обикновено изисква повече време, но може да доведе до добро обобщение за трудни, малки или шумни набори от данни. Тренировките спират според адаптивното минимизиране; Мащабиран конюгиран градиент Този алгоритъм изисква по-малко памет. Обучението автоматично спира, когато започне увеличаване на средната квадратична грешка на валидиращите проби.

След изборът на алгоритъм започва същинското обучение и генериране на невронна мрежа. От получените данни може да се направи оценка на ефективността на мрежата, като се наблюдават получените резултати при обучение, валидиране и тестване. За ефективна се смята мрежата, при която изходните данни и таргетните са възможно най-близо. За най-добра се смята мрежата при която изходните и таргетните данни са равни. В края създадената невронна мрежа може да се тества с останалите 15% тестови данни и да се даде оценка на възможността за практическото и използване.

В първата част на анализа на невронната мрежа, наборът от данни се обучава с различни комбинации от входни променливи, избрани въз основа на резултатите от анализа на основните компоненти и експертни познания.

Пример 1. Съставени са бази данни за предсказването на вида рак под формата на таблица. Таблица 4.1 показва описанието на моделите, създадени с помощта на различни набори от входни променливи.

Данните от таблица 4.1 са създадени след хистология при рак на гърдата от медицински експерт като набор от данни за тестване на експертна система, която ще извърши предполагаемата диагностика. В обхвата на изследването са включени едни от най-важните параметри: размер на формацията, изменение размер на клетката и митоза. Получени са данни за 66 пациента изследвани по 3 признака. Където редовете отговарят на броят изследвани пациенти, а колоните – изследвания признак. В колона А са данните за размерът на формацията, в В изменението в размерът на клетката и в С броят митози. В колона D е отбелязана степента на малигненост (злокачественост) на рака.

Ракът на млечната жлеза е важен здравен проблем със значими обществени и социални последици при жените в целия свят. Той е вторият по честота злокачествен тумор в света и най-често срещаният при жени. Въпреки постигнатите значителни успехи в биологичното и клинично поведение на заболяването и в неговото лечение през последните десетилетия, проблемът продължава да съществува и придобива все по-комплексен характер[13].

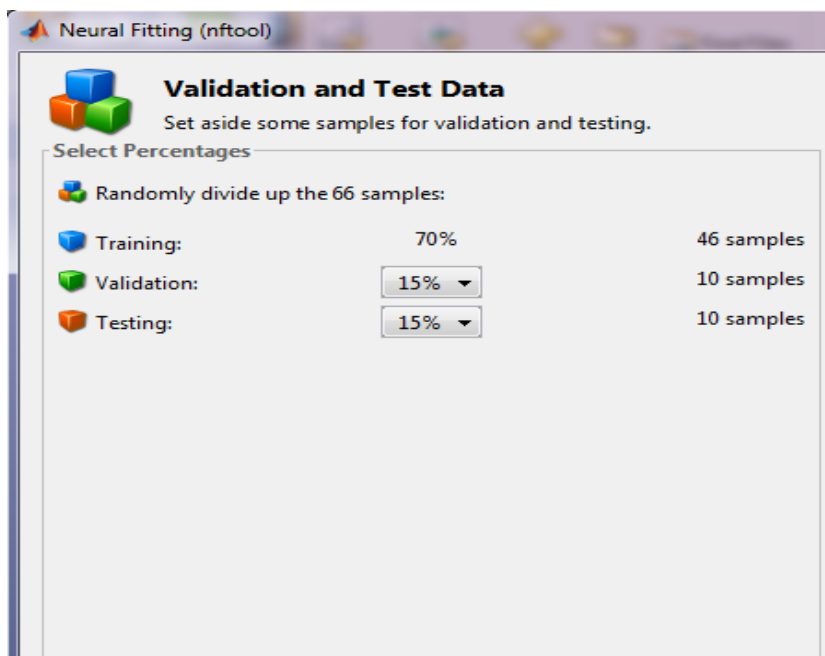
	A	B	C	D		A	B	C	D
1	размер на формацията	изменение размер на клетката	митоза	диагноза	34	10	3	1	1
2	5	1	1	0	35	5	1	1	0
3	1	1	1	0	36	4	8	1	1
4	3	1	1	0	37	5	1	1	0
5	4	1	1	0	38	4	1	1	0
6	5	7	1	1	39	5	1	1	0
7	3	1	1	0	40	3	1	1	0
8	4	1	1	0	41	5	2	1	0
9	8	4	2	1	42	3	1	1	0
10	10	10	1	1	43	1	1	1	0
11	8	10	1	1	44	4	1	1	0
12	7	6	2	1	45	5	4	1	1
13	3	1	1	0	46	5	3	2	1
14	1	1	1	0	47	10	5	3	1
15	10	9	1	1	48	4	1	1	0
16	5	1	1	0	49	1	1	1	0
17	5	1	1	0	50	5	10	1	1
18	1	1	1	0	51	5	1	1	0
19	1	1	1	0	52	10	4	2	1
20	1	1	1	0	53	5	10	1	1
21	5	1	1	0	54	8	10	10	1
22	5	7	1	1	55	2	3	1	0
23	6	10	1	1	56	2	1	1	0
24	3	1	1	0	57	4	1	1	0
25	5	1	1	0	58	3	1	1	0
26	1	1	1	0	59	4	1	1	0
27	8	10	1	1	60	5	1	1	0
28	5	1	1	0	61	3	1	1	0
29	9	8	1	1	62	6	3	1	0
30	5	1	1	0	63	7	1	1	0
31	4	10	1	1	64	1	1	1	0
32	2	5	1	1	65	5	1	1	0
33	10	3	1	1	66	3	1	1	0
					67	4	6	3	1
					68	2	1	1	0

Табл.4.1. База данни от хистология на тумор на млечна жлеза.

За обучението е използван Neural Network Fit Toolbox (nftool). За входните сигнали се получава матрица 66x3, представляваща статични данни: 66 проби от 3 елемента, които включват броят на пациентите и изследваните параметри. За изходните сигнали матрицата е 66x1, представляваща статични данни: 66 проби в 1 елемент, отговарящи броят на пациентите и диагнозата.

Входовете са разделени на случаен принцип в три набора, а именно: обучение, валидиране и тестване. В тази част от анализа са събрани общо 66 набора от данни. Поради ограничения брой налични данни, разпределението на данните за обучение, валидиране и тестване се извършва чрез разпределяне на по-голямата част от данните за обучение. С други думи, за да се поддържа правилно обучение (т.е. коригиране на

тежестите на моделите на невронните мрежи), повечето от данните се използват в процеса на обучение. Следователно данните за обучение, валидиране и тестване са избрани като 70%, 15% и 15% (Фиг.4.1.). В конкретният пример са използвани 46 набора от данни за обучение и по 10 за валидиране и тестване.

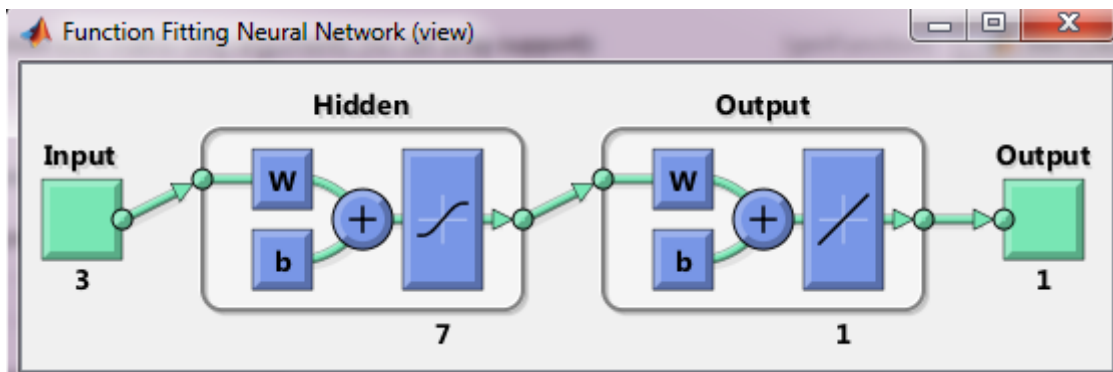


Фиг.4.1. Разпределение на данните по проценти за обучение, тестване, валидиране.

За целта на експеримента е създадена многослойна невронна мрежа с пряко разпространение на сигнала. Тя се характеризира с един входен слой, един скрит и един изходен слой. Възлите, източници на входния сигнал формират входен вектор, който съставя входния сигнал, който се предава на втория слой. Изходните сигнали на втория слой се явяват входни сигнали за третия слой. Така невроните от входния слой и от изходния слой образуват мрежа. Невроните в скрития слой използват трансферна функция за обработка на сигналите, които след това предават на изходния слой. Всеки неврон от скрития и изходния слой е свързан с т.нар. отместване, чиято стойност е винаги 1.

Броят на невроните в скритите слоеве са параметрите с най-голямо влияние върху процеса на обучение. За определянето им в настоящите примери е използвана теоремата на Хетч-Нилсен и Липман [12], която казва че невронна мрежа с един скрит слой и $2N+1$ скрити неврона е достатъчна за N входящи данни. Най-често се използва

един скрит слой. Наличието на два скрити слоя се смята за безсмислено. В нашия случай при 3 входни сигнала скритите неврони са 7.



Фиг.4.2. Многослойна невронна мрежа с пряко разпространение на сигнала.

За анализа на наличните данни е създадена невронна мрежа. Получената мрежа е с еднопосочно предаване и 3 входни сигнала, с 7 неврона в скрития слой. Toolbox за невронна мрежа в Matlab се използва за оценка на ефективността на предложените мрежи. Обучението се извършва с алгоритъма на Levenberg-Marquardt. Този алгоритъм обикновено изисква повече памет, но по-малко време и е най-подходящ. Обучението автоматично спира, когато обобщаването спира да се подобрява, както се посочва от увеличаване на средната квадратична грешка на валидиращите проби.


За да се оцени въздействието на скритите неврони, използвани в скрития слой, броят на скритите неврони може да се променя и да се изграждат различни модели. Използват се различен брой скрити неврони и програмата може се обучава няколко пъти за всеки различен брой скрити неврони, за да се оцени ефектът от избора на данни за обучение върху ефективността на модела. Ефективността на модела се оценява с помощта на средната квадратична грешка (MSE) и коефициента на корелация на Пиърсън (R).

Средноквадратична грешка е средната квадратична разлика между резултатите и целите. По-ниските стойности са по-добри. Нула означава, че няма грешка.

Регресията R измерва корелацията между резултатите и целите. R стойност 1 означава тясна връзка, 0 случайна връзка.

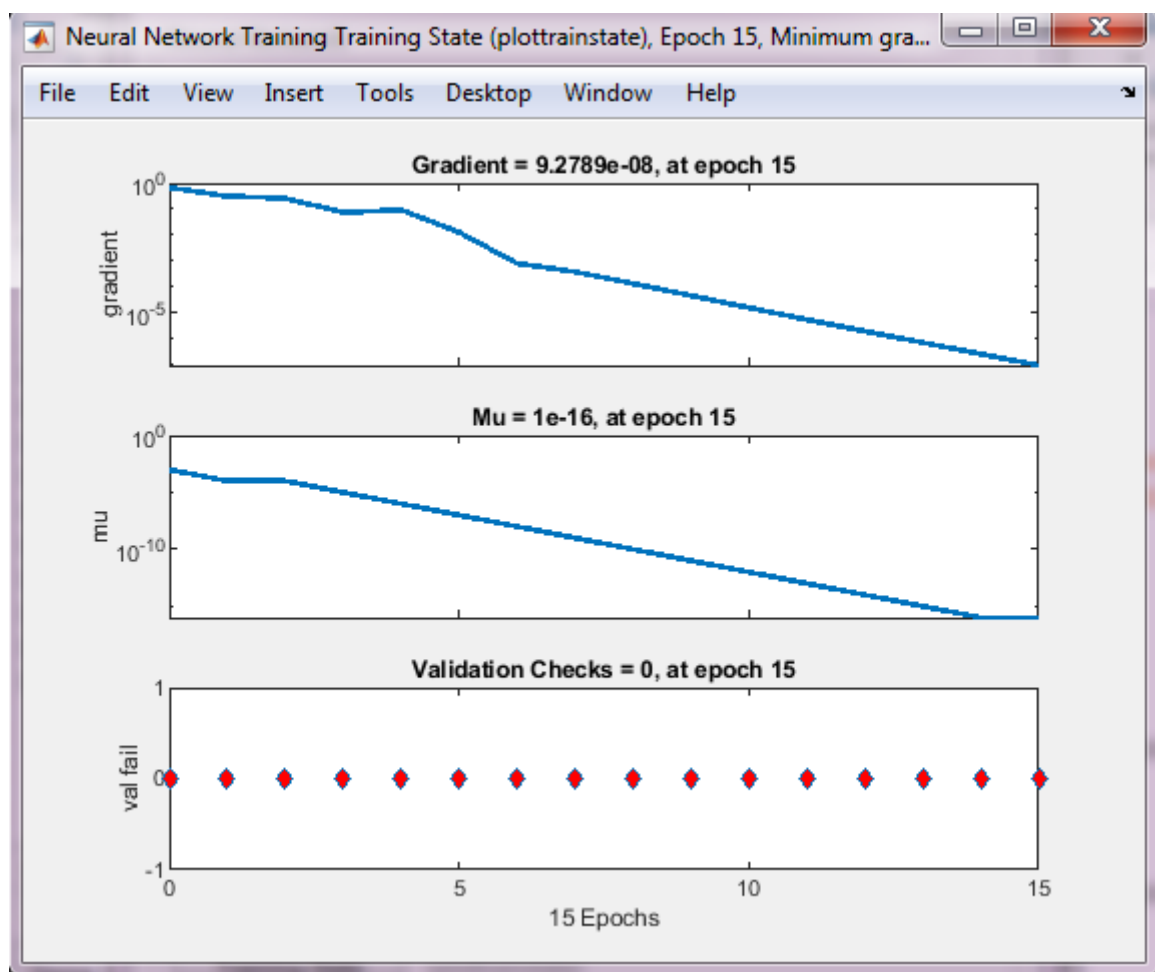
Достига се до минимален градиент в пенадесетия цикъл. Тогава обучението спира. В прозореца на обучението се появява графика на грешките в обучението, грешките при

валидиране и грешките при теста, както е показано на следващата фигура (Фиг. 4.3). В този пример резултатът е разумен поради следните съображения: Крайната средна квадратична грешка е малка, грешката на тестовия набор и грешката на валидиращия набор имат подобни характеристики. Най-доброто изпълнение на валидирането е постигнато в петнадесетия цикъл. Валидирането е 0.0019386. Средната квадратична грешка (MSE) е средната квадратична разлика между изходите и целите. По-ниските стойности са по-добри, докато нулата означава, че няма грешка.



Фиг.4.3. Средноквадратична грешка.

Резултатите от прилагането на методологията на изкуствените невронни мрежи за разграничаване на здрав и нездрав човек въз основа на избрани симптоми показват много добри способности на мрежата да научи моделите, съответстващи на симптомите на човека. Мрежата е симулирана в тестовия набор. Фигура 4.4 показва стойностите на състоянието на обучение за двете мрежи.



Фиг.4.4. Състояние на обучението.

Регресията се използва за проверка на ефективността на мрежата. Следващите графики за регресия показват мрежовите изходи по отношение на цели за обучение, валидиране и тестови набори. За перфектно прилягане данните трябва да попадат по линията от 45 градуса, където мрежовите изходи са равни на целите. За този проблем напасването е сравнително добро за всички набори от данни, като стойностите на R във всички случаи са близки до 1. (Фиг.4.5)



Фиг.4.5. Регресия.

За да се направи оценка на практическото ползване на невронната мрежа се прави сравнение с тестова база данни. Използвани са 25 набора от данни за същите параметри и са представени в таблици 4.2 и 4.3.

	A	B	C
1	размер на формацията	изменение размер на клетката	митоза
2	2	1	1
3	4	1	1
4	6	2	1
5	5	1	1
6	1	1	1
7	8	7	1
8	3	1	1
9	3	1	1
10	10	10	3
11	4	2	1
12	4	1	1
13	5	1	1
14	4	1	1
15	3	1	1
16	3	1	1
17	1	1	1
18	2	1	1
19	3	1	1
20	1	2	1
21	1	1	1
22	5	10	10
23	3	1	1
24	3	1	1
25	1	2	1
26	5	1	1

Табл. 4.2. Тестови данни.

	A
1	тестови резултати
2	0
3	0
4	0
5	0
6	0
7	1
8	0
9	0
10	1
11	0
12	0
13	0
14	0
15	0
16	0
17	0
18	0
19	0
20	0
21	0
22	1
23	0
24	0
25	0
26	0

Табл. 4.3. Тестови резултати за диагноза.

Функцията `sim` в Matlab се използва за симулиране на динамични системи. Използва вече съществуващи параметри и ги сравнява с тестови. От получените стойности се вижда, че в ред 6, 9 и 21 има положителна диагноза за малигнен рак на млечна жлеза (Фиг.4.6). Получените резултати показват, че мрежата е подходяща за практическо ползване.

```
>> a=sim(net8,test)

a =

Columns 1 through 7
    0.0000    -0.0000    0.0098    0.0000   -0.0000    1.0658   -0.0000

Columns 8 through 14
   -0.0073    1.5896    0.0184   -0.0000    0.0044    0.0035   -0.0000

Columns 15 through 21
   -0.0000   -0.0000    0.0000   -0.0000    0.0019    0.0162    1.0724

Columns 22 through 25
   -0.0000    0.0247    0.0436    0.0000
```

Фиг.4.6. Резултати след използване на функция `sim`.

Пример 2. Съставена е база данни с резултати от хистологично изследване за предсказване на малигненост на бъбречноклетъчен карцином. Бъбречноклетъчният карцином е рядко срещан тумор с честота между 3-5% от злокачествените новообразувания у възрастни. Той е на седмо място по честота у мъжете и на десето място по честота от всички злокачествени тумори при жените. Най-засегнатата възраст е 55-75 години, но се среща и в детска и юношеска възраст. При поставяне на диагнозата около 20-3-% от болните са в метастазирал стадий.

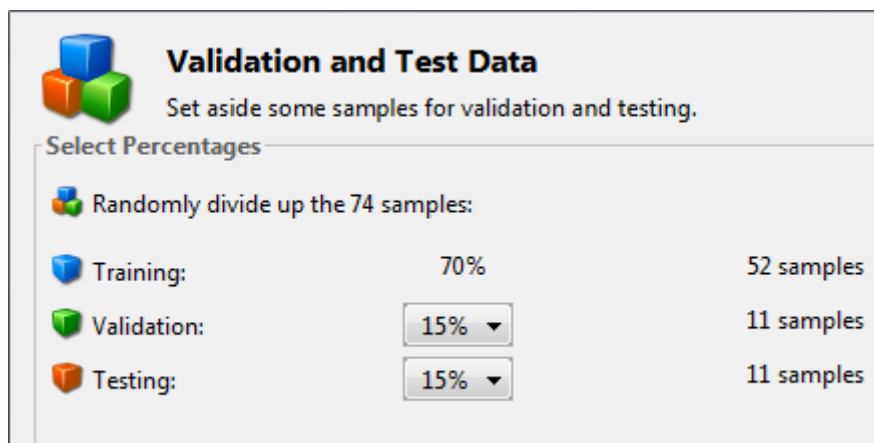
Изследвани са 74 пациента по два критерия. Изследваните параметри са: дезмопластична стромна реакция и високостепенна атипия. Представени са в таблица 4.4.

	A	B		A	B		A	B
1	дезмопластична стромна реакция	високостепенна атипия	31	1	1	62	10	8
2	2	1	32	2	1	63	5	2
3	7	10	33	8	5	64	2	1
4	2	2	34	2	1	65	3	2
5	3	4	35	2	1	66	2	1
6	2	1	36	2	1	67	8	10
7	7	10	37	6	1	68	4	9
8	2	10	38	1	1	69	2	1
9	2	1	39	2	10	70	2	1
10	2	1	40	6	7	71	10	2
11	2	1	41	3	3	72	2	1
12	1	1	42	8	10	73	6	10
13	2	1	43	10	1	74	3	4
14	2	3	44	8	1	75	2	2
15	2	3	45	2	1	76		
16	7	9	46	4	9	77		
17	6	1	47	2	1	78		
18	2	1	48	2	1	79		
19	2	1	49	4	8	80		
20	4	10	50	2	3	81		
21	2	1	51	2	4	82		
22	5	10	52	3	5	83		
23	6	7	53	10	8	84		
24	2	1	54	8	8	85		
25	2	1	55	4	5	86		
26	2	7	56	3	6	87		
27	1	1	57	5	1	88		
28	2	1	58	6	10	89		
29	2	1	59	2	2	90		
30	2	1	60	3	3	91		
			61	2	2	92		

Табл. 4.4. База данни от хистология на бъбречноклетъчен карцином

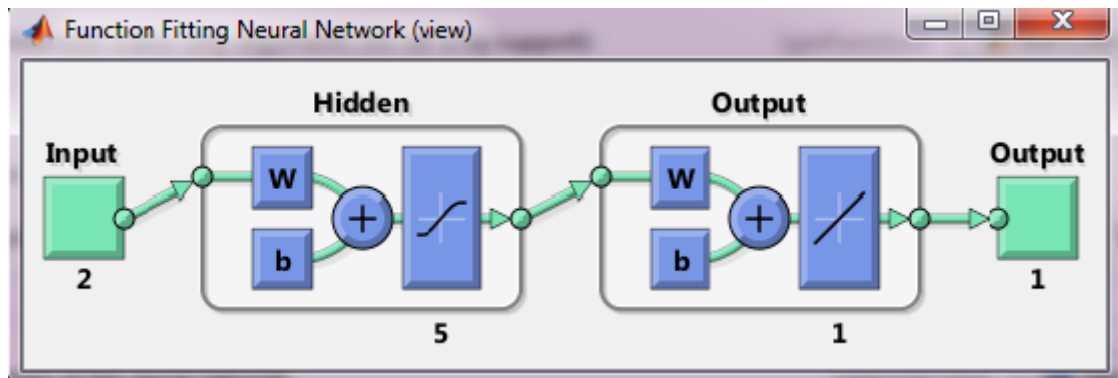
За създаването на невронната мрежа за входен сигнал се използва матрицата 44x2, която съответства на 44 изследвани пациента по 2 параметъра.

За обучение се използват на случаен принцип разпределени 70% от наличните данни или 52 набора от данни, 15% са за валидиране и 15% за тестване или по 11 набора данни. (Фиг 4.7)



Фиг. 4.7. Разпределение на данните по проценти за обучение, тестване, валидиране

Създадената невронна мрежа е многослойна с право разпределение на сигнала. Тя се характеризира с един входен слой, един скрит и един изходен слой. Разположението на данните е 2 неврона във входния слой, 5 неврона в скрити слой и 1 изходен сигнал. Невроните в скрития слой са определени по формулата $2N+1$.

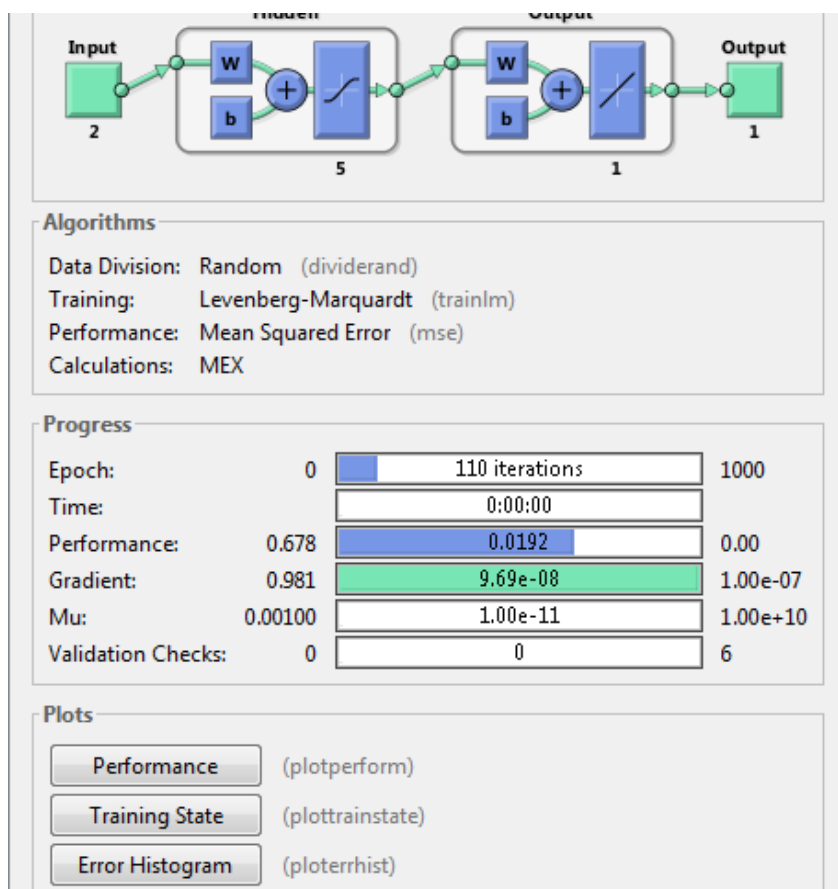


Фиг. 4.8. Многослойна невронна мрежа с пряко разпространение на сигнала

Сега мрежата е готова за обучение. Пробите автоматично се разделят на обучителни, валидиращи и тестови набори. Обучението продължава, докато мрежата продължава да се подобрява по отношение на валидирането. Тестването осигурява напълно независима мярка за точност на мрежата.

Инструментът за обучение на невронна мрежа показва мрежата, която се обучава, и алгоритмите, използвани за нейното обучение. Той също така показва състоянието на обучение по време на обучение и критериите, които са спрели обучението, ще бъдат

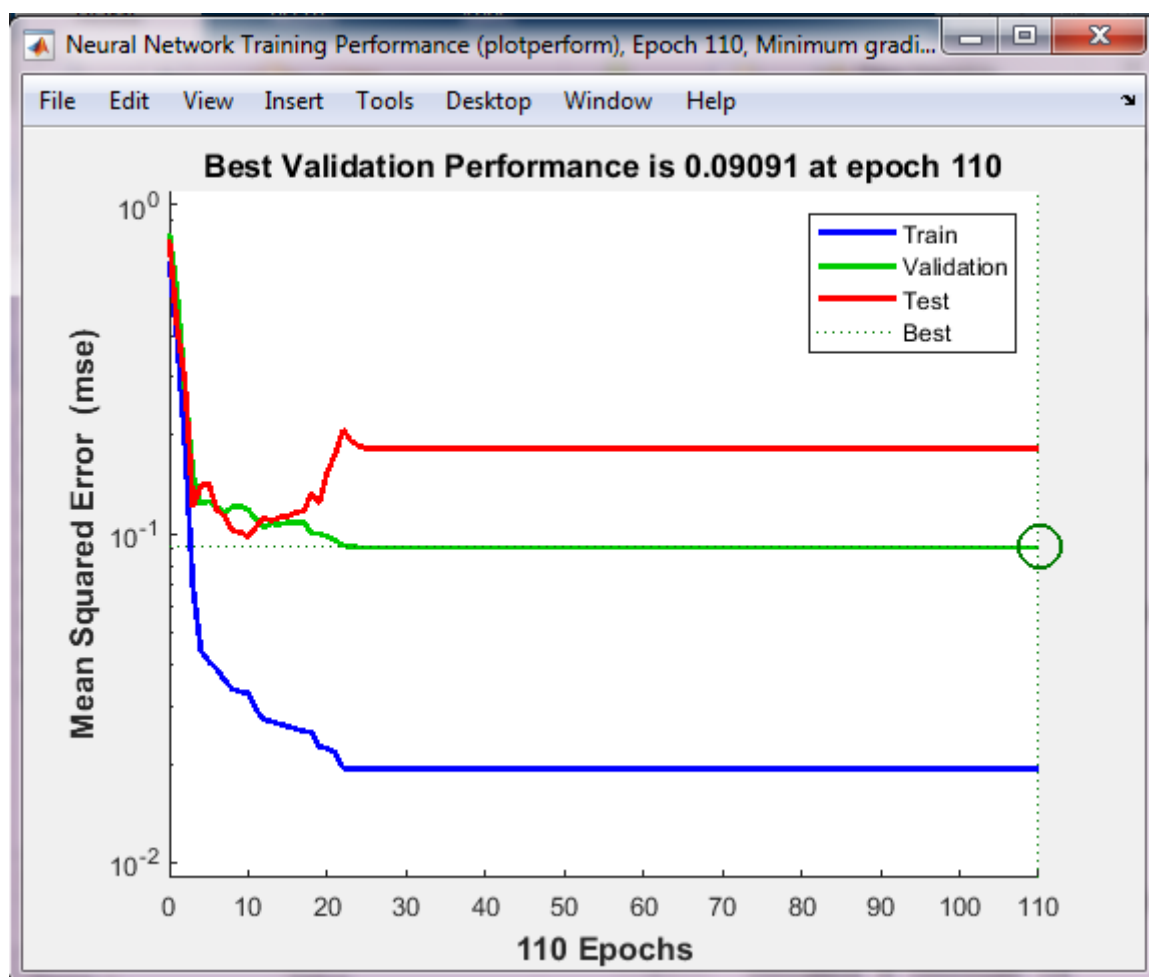
маркирани в зелено. Бутоните в долната част отварят полезни графики, които могат да се отворят по време и след тренировка. (Фиг.4.9)



Фиг. 4.9. Процес на обучение на мрежата.

Следващата стъпка е избиране на алгоритъм за обучение на мрежата. Използван е алгоритъмът на Levenberg-Marquardt. Този алгоритъм е най-бърз и е най-подходящ. Обучението автоматично спира, когато обобщаването спира да се подобрява, както се посочва от увеличаване на средната квадратична грешка на валидиращите проби.

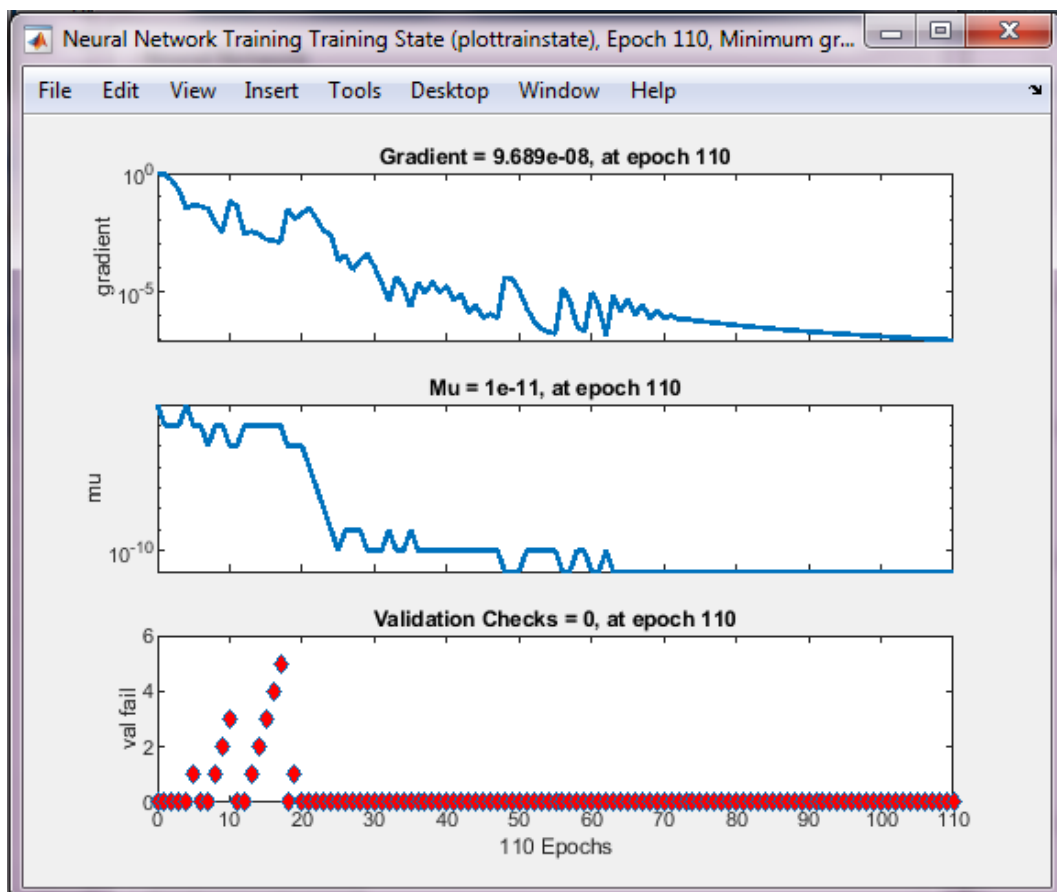
Ефективността на модела се оценява с помощта на средната квадратична грешка (MSE) и коефициента на корелация на Пиърсън (R).



Фиг. 4.10. Средноквадратична грешка.

Достига се до минимален градиент в сто и десият цикъл. Тогава обучението спира. В прозореца на обучението се появява графика на грешките в обучението, грешките при валидиране и грешките при теста, както е показано на следващата фигура (Фиг. 4.10). В този пример резултатът е разумен поради следните съображения: Крайната средна квадратична грешка е малка, грешката на тестовия набор и грешката на валидацията набор имат подобни характеристики. Най-доброто изпълнение на валидирането е постигнато в 110 цикъл. Валидирането е 0.09091. Средната квадратична грешка (MSE) е средната квадратична разлика между изходите и целите. По-ниските стойности са по-добри, докато нулата означава, че няма грешка.

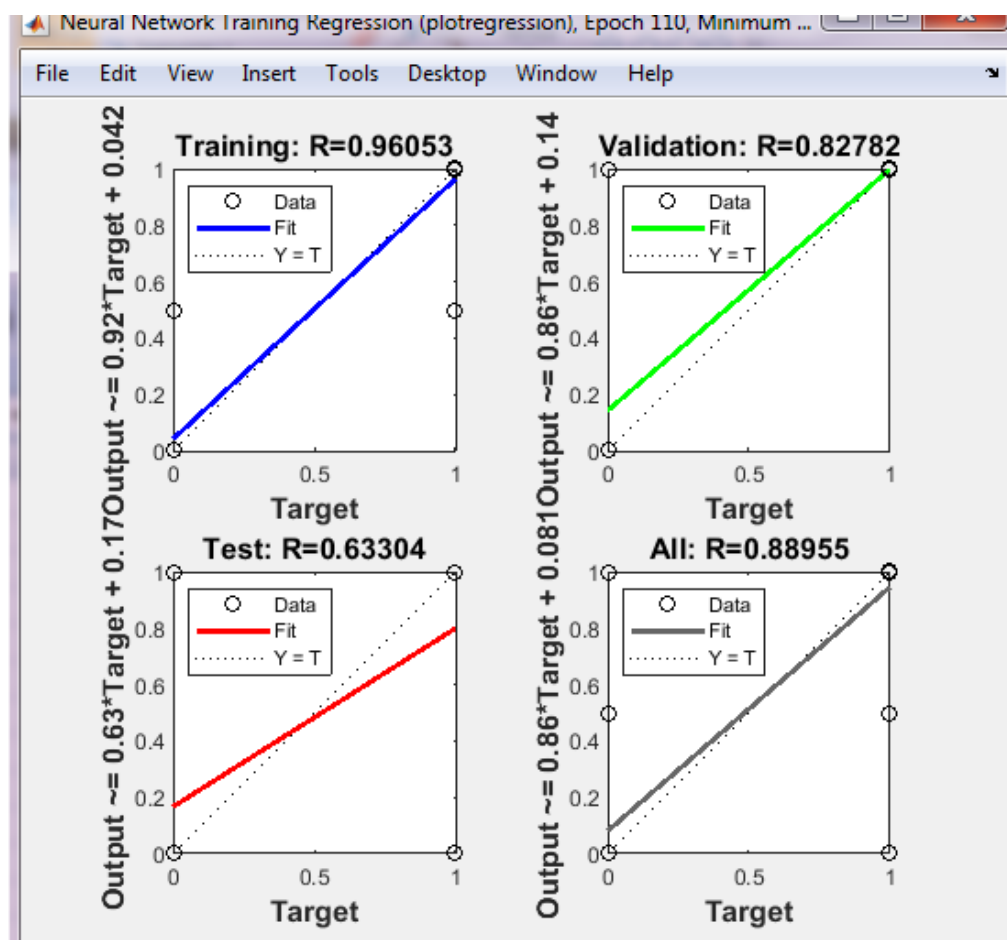
Фиг. 4.11. показва състоянието на обучението на мрежата в 110 цикъл.



Фиг. 4.11. Състояние н обучението.

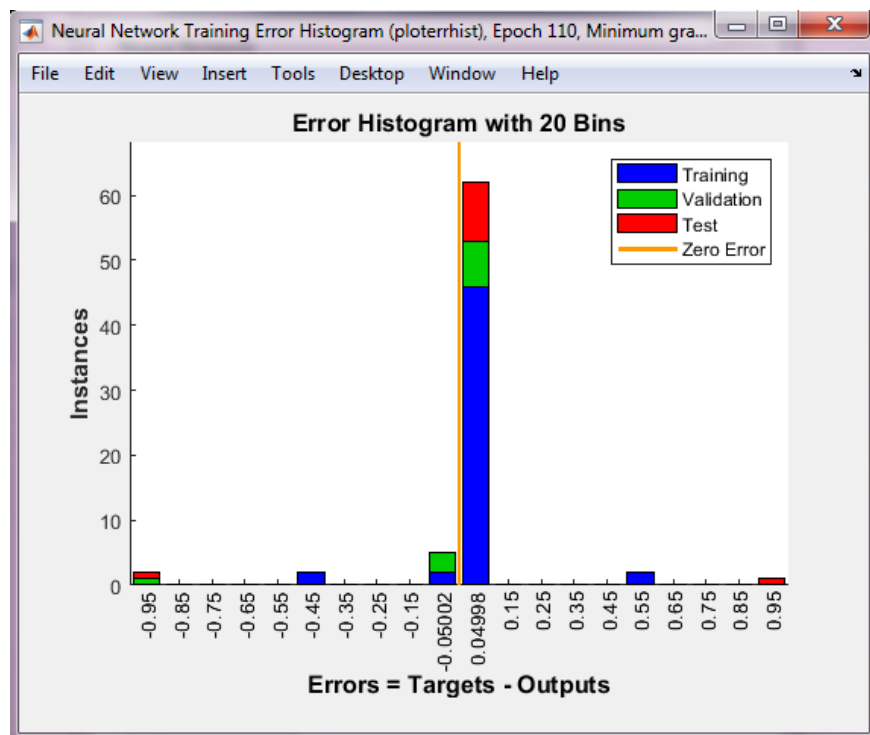
Друга мярка за това колко добре невронната мрежа отговаря на данните е графиката на регресията. Тук регресията се нанася върху всички проби.

Графиката на регресията показва действителните мрежови изходи, разположени по отношение на свързаните таргетни стойности. Ако мрежата се е научила да пасва добре на данните, линейното прилягане към тази връзка изход-таргет трябва да бъде близо до долния ляв и горния десен ъгъл на графиката. (Фиг. 4.12)



Фиг. 4.12. Регресия.

Друга мярка за това колко добре невронната мрежа има подходящи данни е хистограмата на грешката. Тя показва как се разпределят размерите на грешките. В случая повечето точки са разположени около нулата. (Фиг.4.13)



Фиг.4.13. Хистограма на грешките.

Последната стъпка е симулиране на динамични системи. Получените резултати се сравняват с тестов набор от данни чрез функцията `sim`.

```
>> a=sim(net3,test)

a =

Columns 1 through 7
-0.0000 -0.0000 -0.0000 -0.0000 1.0188 1.0000 1.0000

Columns 8 through 14
1.0000 -0.0000 -0.0000 -0.0000 -0.0000 -0.0000 -0.0000

Columns 15 through 21
-0.0000 -0.0000 -0.0000 -0.0000 1.0000 1.0000 1.0000

>>
```

Фиг.4.14. Резултати след използване на функцията `sim`.

От получените данни след обучение на мрежата и сравнението им с тестовите от таблица 4.5 може да се оцени практическото приложение на мрежата. В редове 5, 6, 7,8, 19, 20 и 21 има малигнен карцином.

	А	В		А
	дезмопластична	високостепенн	1	диагноза
1	стромна реакция	а атипия	2	0
2	1	1	3	0
3	1	1	4	0
4	1	1	5	0
5	1	1	6	1
6	10	7	7	1
7	10	10	8	1
8	4	1	9	1
9	8	3	10	0
10	1	1	11	0
11	1	1	12	0
12	1	1	13	0
13	1	1	14	0
14	1	1	15	0
15	1	1	16	0
16	1	1	17	0
17	1	1	18	0
18	1	1	19	0
19	1	1	20	1
20	9	10	21	1
21	9	4	22	1
22	10	2	23	

Табл.4.5. Тестов набор от данни

Глава 5. Изводи и заключение.

Основната цел на дипломната работа е разработване на невронна мрежа, с приложение за медицинска диагностика. Развитието на медицинската наука е основа за реализирането и развитието на невронните мрежи и машинното обучение, които от своя страна се използват за постигане на конкретни цели в медицината.

Описани са най-използваните структури невронни мрежи. Те са широко разпространени алгоритмични подходи – структура, която реално имитира връзките в човешкия мозък. Докато невронните мрежи обработват данните, мрежата от свързани елементи се самонастройва и дава възможност на невронните мрежи да тълкуват постъпващите бъдещи данни. Използването на невронни мрежи се базира на алгоритми за обучение чрез примери, с което се прави опит за моделиране на биологичния им еквивалент - човешкия мозък. Предложена е многослойна невронна мрежа с пряко разпространение на сигнала с контролирано обучение за диагностициране. Информацията се движи само в една посока, напред, от входните възли, през скритите възли и към изходните възли.

Разгледано е приложението на невронните мрежи за целите на медицинската диагностика. Интелигентната система за медицинска диагностика може да осигури помощ за пациенти и медицински експерти. Интелигентната система може да послужи за подобряване на качеството на медицинската диагноза.

Комплектувани са данни от медицинската практика за диагностика на рак на млечната жлеза и белодробноклетъчен карцином. Използвани са данни от медицински изследвания във вид на матрици, които да оценят степента на малигненост на тумора.

Обучена е и тествана невронна мрежа за подпомагане на вземане на решение при диагностициране на рак на млечната жлеза и бъбречноклетъчен карцином. Използван е софтуер Matlab, който се използва за създаването на невронната мрежа, която се обучава, валидира и тества. Така може да се оцени практическото приложение на мрежата. Изчислява се средноквадратична грешка, регресия, създава се хистограма на грешките. Ако резултатът не е удовлетворителен за по-точни такива, може да преобучи мрежата, като се натисне бутонът Преобучение (Retrain) в nftool. Това ще промени първоначалните тегла на мрежата и може да се създаде подобрена мрежа след преобучение.

Системите на изкуствения интелект трябва да направят възможно решението на следните три задачи: придобиване на знания, използване на натрупаните знания за решение на проблеми и извличане на знания от опита. Резултатите показват, че предложената диагноза невронната мрежа може да бъде полезна за подпомагане окончателната диагноза на медицинския специалист.

Литература:

1. S. N. Sivanandam, S. Sumathi, S. N. Deepa. *Introduction to neural networks using Matlab*.
2. Rüdiger W. Brause. *Medical Analysis and Diagnosis by Neural Networks*.
3. Christopher M Bishop. *Neural networks for pattern recognition*. Oxford university press, 1995.
4. Frank Harary. *Graph theory*. 1969.
5. Gary Chartrand, Linda Lesniak, and Ping Zhang. *Graphs & digraphs*. CRC Press, 2010.
6. Věra Kurková. *Kolmogorov's theorem and multilayer neural networks*. *Neural networks*, 5(3):501–506, 1992.
7. J. A. Freeman and D. M. Skapura, *Neural networks: algorithms, applications and programming techniques*, Addison Wesley Longman, 1991.
8. <http://www.newweirdscience.com/nevmreji.pdf>
9. Размито управление и невронни мрежи – Валери Младенов, Снежана Йорданова, факултет Автоматика, Технически университет – София, 2006.
10. Приложение на невронните мрежи в компютърното моделиране – Ганчо Венков, Богдан Гилев, Технически университет – София, 2009.
11. Нейронные сети. MATLAB 6 – В.С. Медведев, В.Г. Потёмкин, Москва 2002
12. Lippmann, R. P., “An Introduction to Computing with Neural Nets”, IEEE ASSP Magazine, pp. 4-23, April 1987.
13. Проф. Д-р Константа В. Тимчева, дм, *Медицинска онкология част 2*, Издателство „Парадигма”, 2018.
14. Filippo Amato¹, Alberto López¹, Eladia María Peña-Méndez, Petr Vaňhara, Aleš Hampl, Josef Havel. *Artificial neural networks in medical diagnosis*. *J Appl Biomed*. 11: 47–58, 2013.